Post-training of Language Models

Hà Thanh Phong – 24520024
Hà Xuân Thiện – 24520031
Trần Quang Trường – 24521901

University of Information Technology – VNUHCM

Ngày 29 tháng 10 năm 2026

Mục lục

01 Supervised Fine-Tuning (SFT)
Từ dự đoán văn bản đến làm theo chỉ thị.

02 Alignment với RLHF và PPO
Học từ cặp đối chiếu và phần thưởng.

03 DPO và các biến thể
Tối ưu trực tiếp từ dữ liệu sở thích.

04 RLVR và GRPO
Kiểm chứng kết quả và học suy luận.

05 Knowledge Distillation
Chuyển năng lực từ Teacher Model sang Student Model;
LoRA, Model Merging và đánh giá hệ thống.

PHẦN 1 / 05

Supervised Fine-Tuning (SFT)

2020–2021

Nội dung: Base Model, mục tiêu chỉ thị, dữ liệu và SFT Loss.

Mục tiêu dự đoán token tiếp theo của Base Model.

Mục tiêu dự đoán token tiếp theo

$$\mathcal{L}_{\text{Pretrain}}(\theta) = -\sum_{t=1}^{T} \log P_\theta(u_t \mid u_1, u_2, \ldots, u_{t-1})$$

Base Model học được gì?

- **Xấp xỉ phân phối biên ngôn ngữ:** Học phân phối có điều kiện $P_\theta(u_t \mid u_{<t})$.
- **Nội hóa tri thức thế giới:** Nén cú pháp, tri thức sự kiện (factual knowledge) và quy luật suy diễn.

Giới hạn của Pre-training

Dự đoán văn bản và giải quyết yêu cầu là hai mục tiêu khác nhau.

- **Objective Mismatch:**
  - Đầu vào x: *"Giải thích nguyên lý của laser?"*
  - Đầu ra Base Model: Sinh tiếp các câu hỏi số 2, số 3 thay vì trả lời.
- **Không phân biệt chất lượng dữ liệu:**
  - Tái tạo cả sai số thực tế, định kiến và nội dung độc hại từ tập dữ liệu web.

Mục tiêu của Post-training

Định hướng phân phối phản hồi: Chuyển dịch từ $P_\theta(u_t \mid u_{<t})$ sang phân phối phản hồi theo chỉ thị $\pi_\theta(y \mid x)$.

Ba tiêu chuẩn căn chỉnh (3H Criteria):

1. **Helpful (Hữu ích):** Giải quyết đúng yêu cầu.
2. **Honest (Trung thực):** Hạn chế bịa đặt thông tin.
3. **Harmless (Vô hại):** Từ chối tác vụ độc hại.

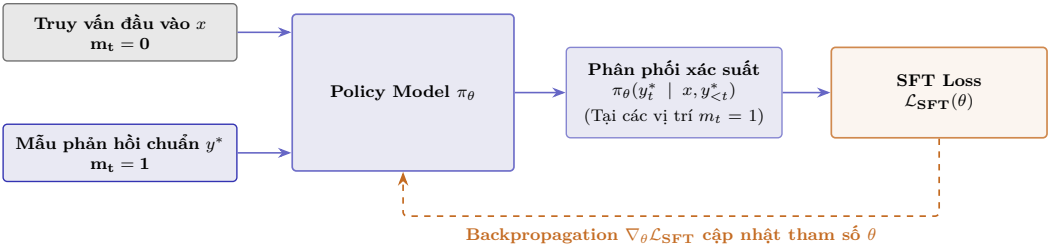
Dữ liệu SFT và khuôn mẫu hội thoại

SFT học bắt chước phản hồi của chuyên gia (Wei et al., 2022).

Dữ liệu và Control Tokens

- **Tập dữ liệu:** $\mathcal{D}_{\text{SFT}} = \{(x^{(i)}, y^{*(i)})\}_{i=1}^{N}$ gồm truy vấn đầu vào x và mẫu phản hồi chuẩn y^*.
- **Phân vùng ngữ cảnh bằng Control Tokens:**
  - `<|im_start|>system ... <|im_end|>` $\longrightarrow$ Ràng buộc hệ thống toàn cục.
  - `<|im_start|>user ... <|im_end|>` $\longrightarrow$ Miền truy vấn đầu vào x.
  - `<|im_start|>assistant ... <|im_end|>` $\longrightarrow$ Miền sinh phản hồi mục tiêu y^*.

SFT: luồng dữ liệu và Loss Masking



Quy trình huấn luyện SFT với Loss Masking.

Conditional Maximum Likelihood Estimation (MLE).

SFT Loss (Conditional MLE)

$$\mathcal{L}_{\mathrm{SFT}}(\theta) = -\,\mathbb{E}_{(x,y^*)\sim\mathcal{D}_{\mathrm{SFT}}}\left[\sum_{t=1}^{|y^*|}\log \pi_\theta\big(y_t^* \mid x, y_1^*, \ldots, y_{t-1}^*\big)\right]$$

Ý nghĩa các ký hiệu trong công thức

- θ, π_θ: Tham số cần tối ưu và mô hình chính sách.
- $\mathcal{D}_{\mathrm{SFT}}$: Tập dữ liệu gồm các cặp prompt–phản hồi (x, y^*).
- $y^*_{<t}$: Ngữ cảnh tiền tố $y_1^*, \ldots, y_{t-1}^*$.

Chất lượng dữ liệu: Giả thuyết LIMA

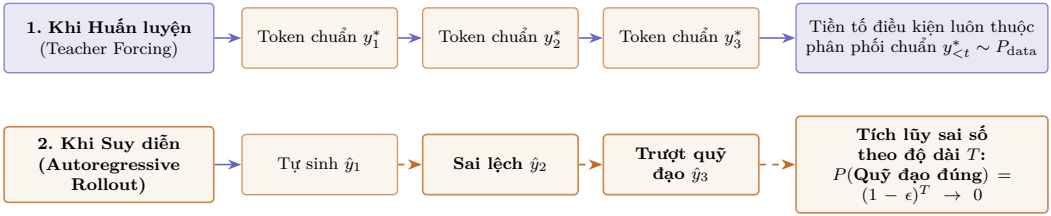
Zhou et al., 2023 – Less Is More for Alignment (LIMA).

Superficial Alignment Hypothesis

- **Tri thức từ Pre-training:** Toàn bộ tri thức thế giới và năng lực suy luận đã được tiếp thu ở giai đoạn Pre-training.
- **Bản chất của SFT:** SFT chỉ đóng vai trò học phong cách (style), định dạng hội thoại và phong thái trợ lý.
- **Không tạo tri thức mới:** SFT không nạp thêm kiến thức mới mà chỉ kích hoạt tri thức sẵn có theo chỉ thị.

SFT: huấn luyện và suy diễn

Teacher forcing dùng tiền tố chuẩn; Autoregressive Decoding dùng tiền tố tự sinh.



Khi huấn luyện: $s_t = (x, y^*_{<t}) \sim P_{\text{data}}$. Khi suy diễn: $\hat{s}_t = (x, \hat{y}_{<t}) \sim \pi_\theta$.
Với $\epsilon = 0.01$, $T = 200$, xác suất giữ đúng quỹ đạo giảm còn $(0.99)^{200} \approx 13.4\%$.

Hạn chế của SFT

1. **Exposure Bias:**
   Mô hình chỉ quan sát tiền tố mẫu $y^*_{<t} \sim P_{\text{data}}$, chưa bao giờ được huấn luyện trên chuỗi tự sinh $\hat{y} \sim \pi_\theta$.
2. **Extrinsic Hallucination:**
   Cực đại hóa $\log \pi_\theta(y^* \mid x)$ trên cả tri thức nằm ngoài Base Model khiến mô hình suy giảm hiệu chỉnh xác suất (Miscalibration) và sinh thông tin bịa đặt.
3. **Absence of Negative Samples:**
   SFT chỉ gia tăng xác suất cho mẫu dương chuẩn y^* ($\uparrow$), không có gradient phạt ($\downarrow$) đối với các mẫu âm sai lệch y_l.

PHẦN 2 / 05

Alignment với RLHF và PPO

2022–đầu 2023

Nội dung: Sở thích cặp, Reward Model, KL regularization và kiến trúc bốn mạng.

InstructGPT chuyển từ mẫu đơn sang quan hệ thứ tự (Ouyang et al., 2022).

Sinh phản hồi và đánh giá phản hồi

Thay vì soạn nhãn chuẩn y^* như SFT, cho mô hình sinh cặp ứng viên $(y_1, y_2) \sim \pi_{\text{SFT}}(\cdot \mid x)$ rồi xác lập thứ tự $\mathbf{y_w} \succ \mathbf{y_l}$ (**Mẫu dương** y_w ưu việt hơn **Mẫu âm** y_l):

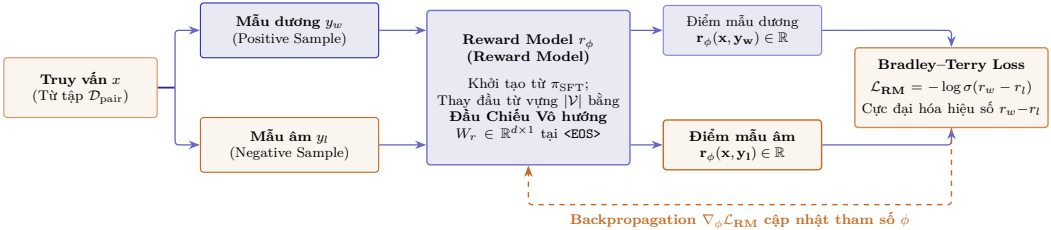
Vì sao không chỉ chấm điểm tuyệt đối?

- **Phương sai cá nhân cao:** Thang điểm tuyệt đối (1–10) không đồng nhất giữa những người đánh giá.
- **Calibration Drift:** Ngưỡng chấm của cùng một chuyên gia biến thiên theo thời gian.

Ưu thế của cặp đối chiếu ($y_w \succ y_l$)

- **Bất biến với thang đo:** Quan hệ nhị phân $y_w \succ y_l$ có độ đồng thuận thống kê cao.
- **Bổ sung Mẫu âm y_l (Negative Sample):** Cung cấp biên phân cách rõ ràng để triệt tiêu hành vi sai lệch.

Học điểm vô hướng $r_\phi(x, y) \in \mathbb{R}$ từ cặp mẫu dương và mẫu âm.



Nguyên lý vận hành: Cặp (x, y_w) và (x, y_l) đi qua cùng mạng r_ϕ; gradient đẩy điểm của mẫu dương $r_\phi(x, y_w)$ tăng lên ($\uparrow$) và điểm của mẫu âm $r_\phi(x, y_l)$ giảm xuống ($\downarrow$).

Maximum Likelihood Estimation cho quan hệ thứ tự cặp.

Bradley–Terry (1952) và Loss $\mathcal{L}_{\text{RM}}(\phi)$

$$P(y_w \succ y_l \mid x) = \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big), \qquad \mathcal{L}_{\text{RM}}(\phi) = -\,\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}_{\text{pair}}}\Big[\log \sigma\big(r_\phi(x, y_w) - r_\phi(x, y_l)\big)\Big]$$

Bất biến tịnh tiến (Shift invariance)

- **Biểu diễn vô hướng tại `<EOS>`:** $r_\phi(x, y) = W_r^\top h_{\text{EOS}}(x, y) \in \mathbb{R}$ (do mặt nạ Causal Attention hội tụ toàn bộ tiền tố tại token cuối).
- **Bất biến tịnh tiến:** Với mọi hàm $C(x)$ chỉ phụ thuộc truy vấn x, phép biến đổi $\tilde{r}(x, y) = r(x, y) + C(x)$ bảo toàn hiệu số:

$$\tilde{r}(x, y_w) - \tilde{r}(x, y_l) = r(x, y_w) - r(x, y_l) \implies P_{\tilde{r}}(y_w \succ y_l \mid x) \equiv P_r(y_w \succ y_l \mid x)$$

Vì sao cần phạt KL divergence?

Tối đa hóa trực tiếp $\mathbb{E}[r_\phi(x, y)]$ có thể làm suy biến phân phối.

Goodhart và Reward Hacking

- **Định luật Goodhart:** Khi hàm xấp xỉ r_ϕ bị tối ưu hóa cực đoan, nó mất tính tương quan với chất lượng thực tế.
- **OOD Error:** r_ϕ chỉ chính xác trong lân cận phân phối của π_{SFT}.
- **Reward Hacking (Gao et al., 2023):** Policy π_θ dịch chuyển sang vùng ngoại lai để khai thác cực đại giả của r_ϕ.

Điều chuẩn vùng tin cậy bằng D_{KL}

- Cố định mô hình SFT làm **Reference Model (π_{ref})** và phạt độ lệch phân phối:

$$\mathrm{D}_{\text{KL}}\left(\pi_\theta(\cdot \mid x) \,\|\, \pi_{\text{ref}}(\cdot \mid x)\right) = \mathbb{E}_{y\sim\pi_\theta}\left[\log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right]$$

- **Tác dụng:** Neo π_θ trong vùng tin cậy của r_ϕ và bảo toàn cấu trúc ngôn ngữ gốc.

Tối đa hóa phần thưởng và KL regularization (Ouyang et al., 2022).

Mục tiêu RLHF có KL regularization

$$\max_{\pi_\theta} J_{\text{RLHF}}(\pi_\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(y|x)} \Big[\underbrace{r_\phi(x,y)}_{\text{Điểm định giá } r_\phi} - \beta \underbrace{\log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}}_{\text{KL regularization}} \Big]$$

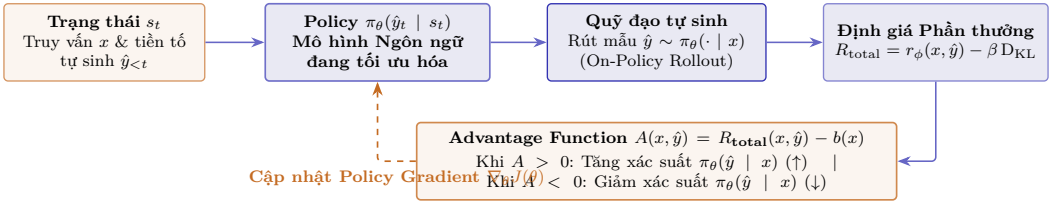
Phần thưởng hiệu dụng và hệ số $\beta > 0$

- Phần thưởng tổng hợp tại mỗi bước lấy mẫu trực tuyến $y \sim \pi_\theta(\cdot \mid x)$:

$$R_{\text{total}}(x,y) = r_\phi(x,y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)}$$

- **Giới hạn tiệm cận:** Khi $\beta \to 0 \implies$ suy biến do *Reward Hacking*; khi $\beta \to +\infty \implies$ Policy bất động ($\pi_\theta \equiv \pi_{\text{ref}}$).

Policy tự sinh mẫu $\hat{y} \sim \pi_\theta$ rồi nhận phản hồi để cập nhật.



Khắc phục Exposure Bias: Policy π_θ được huấn luyện trực tiếp trên các trạng thái tự sinh $\hat{s}_t = (x, \hat{y}_{<t}) \sim \pi_\theta$ và nhận phạt âm ($A < 0$) ngay khi đi chệch quỹ đạo.

REINFORCE xử lý phép lấy mẫu token rời rạc (Williams, 1992).

REINFORCE với baseline và Advantage $A(x, y)$

$$\nabla_\theta J(\theta) = \mathbb{E}_{x\sim\mathcal{D},\, y\sim\pi_\theta(\cdot|x)} \Big[\underbrace{\big(R_{\text{total}}(x,y) - b(x)\big)}_{\text{Advantage Function } A(x,y)} \nabla_\theta \log \pi_\theta(y \mid x) \Big]$$

Đồng nhất thức gradient logarit

- Phép rút mẫu rời rạc $y \sim \pi_\theta$ không có gradient $\frac{\partial y}{\partial \theta}$.
- Áp dụng $\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \log \pi_\theta$:

$$\nabla_\theta \sum_y \pi_\theta(y) R(y) = \mathbb{E}_{y\sim\pi_\theta} \left[R(y) \nabla_\theta \log \pi_\theta(y) \right]$$

Vai trò của baseline $b(x) = \mathbb{E}[R]$

- Phân tách dấu giữa quỹ đạo trên trung bình ($A > 0, \uparrow$) và dưới trung bình ($A < 0, \downarrow$).
- Giảm phương sai ước lượng Monte Carlo mà không làm chệch kỳ vọng (do $\mathbb{E}[b(x) \nabla_\theta \log \pi_\theta] = 0$).

Kết hợp PPO-Clip và Critic (Schulman et al., 2017).

PPO-Clip Objective

$$\mathcal{J}_{\text{PPO-Clip}}(\theta) = \mathbb{E}_t\left[\min\left(\rho_t(\theta)\hat{A}_t,\ \text{clip}\left(\rho_t(\theta), 1-\epsilon, 1+\epsilon\right)\hat{A}_t\right)\right], \qquad \rho_t(\theta) = \frac{\pi_\theta(y_t \mid x, y_{<t})}{\pi_{\theta_{\text{old}}}(y_t \mid x, y_{<t})}$$

Clipping $\text{clip}(\rho_t, 1-\epsilon, 1+\epsilon)$

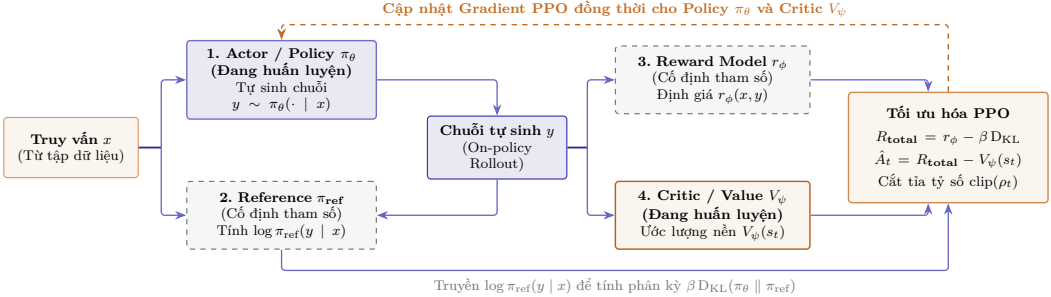
- $\rho_t(\theta)$: Tỷ số xác suất của token y_t giữa Policy mới và Policy lúc lấy mẫu.
- Khi $|\rho_t(\theta) - 1| > \epsilon$ (với $\epsilon = 0.2$), toán tử $\min(\cdot)$ triệt tiêu gradient về 0, ngăn bước cập nhật quá lớn.

Critic $V_\psi(s_t)$

- Ước lượng baseline kỳ vọng tại từng vị trí token t: $\hat{A}_t = R_t - V_\psi(s_t)$.
- Đòi hỏi duy trì một mạng nơ-ron V_ψ có quy mô tham số tương đương mô hình chính π_θ.

RLHF + PPO: bốn mô hình phối hợp

Actor, Reference, Reward Model và Critic cùng hoạt động trên GPU.



RLHF + PPO cải thiện SFT như thế nào?

Đối chiếu RLHF + PPO (2022) và SFT (2021).

Đóng góp so với SFT

Tiêu chí đánh giá	SFT (Phần 1 – 2021)	RLHF + PPO (Phần 2 – 2022)
1. Phân phối trạng thái	Học tĩnh trên tiền tố chuyên gia $y^*_{<t}$ (*Teacher Forcing*)	**Khử Exposure Bias**: Học on-policy trên chuỗi tự sinh $\hat{y} \sim \pi_\theta$ (*On-policy*)
2. Tín hiệu gradient	Chỉ có tín hiệu dương ($\uparrow$) trên mẫu chuẩn y^*	**Gradient hai chiều**: Củng cố mẫu dương ($\hat{A}_t > 0, \uparrow$) và chế tài mẫu âm ($\hat{A}_t < 0, \downarrow$)
3. Kiểm soát phân phối	Suy giảm hiệu chỉnh xác suất khi ép học thuộc	Điều chuẩn vùng tin cậy $\beta\, \mathrm{D}_{\mathrm{KL}}(\pi_\theta \,\|\, \pi_{\mathrm{ref}})$ chống suy biến
4. Hiệu năng thực nghiệm	Phụ thuộc mạnh vào kích thước Base Model	**InstructGPT 1.3B** vượt qua **GPT-3 175B** trên đánh giá mù

Các điểm nghẽn của RLHF + PPO

Chi phí bộ nhớ, thời gian sinh mẫu và tính ổn định dẫn đến DPO (2023).

Ba điểm nghẽn hệ thống

1. **Chi phí Bộ nhớ GPU gấp 4 lần (4-Model Memory Bottleneck):**
   Cần nạp đồng thời **4 mạng nơ-ron lớn** $(\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi)$ vào VRAM.
2. **Thời gian Autoregressive Decoding (Autoregressive Rollout Bottleneck):**
   Sinh mẫu tuần tự $\hat{y} \sim \pi_\theta$ tại mỗi bước cập nhật tiêu tốn $> 70\%$ thời gian tính toán.
3. **Phương sai gradient cao và sai số xấp xỉ kép (r_ϕ, V_ψ):**
   Sai số ước lượng từ cả Reward Model r_ϕ lẫn Value Network V_ψ gây mất ổn định hội tụ.

Tiếp theo: DPO (2023)

Dùng **closed-form solution** của RLHF để cập nhật trực tiếp π_θ từ cặp mẫu dương/âm (y_w, y_l) mà **bỏ hoàn toàn vòng lặp RL, bỏ cả r_ϕ lẫn V_ψ.**

PHẦN 3 / 05

DPO và các biến thể

2023–2024

Nội dung: closed-form solution, gradient, kiến trúc hai mô hình và các hướng cải tiến.

Năm giai đoạn của Post-training: từ SFT đến Knowledge Distillation

DPO: tối ưu trực tiếp từ sở thích

Thay vòng lặp RL bốn mô hình bằng closed-form solution (Rafailov et al., 2023).

Liên hệ trực tiếp Reward Function $r(x, y)$ và Policy $\pi^*(y \mid x)$

- **Quy trình gián tiếp của RLHF + PPO (Phần 2):**

$$\text{Cặp } (y_w, y_l) \xrightarrow{\text{Bước 1 (MLE)}} \text{Reward Function } r_\phi(x, y) \xrightarrow{\text{Bước 2 (PPO + } V_\psi)} \text{Policy } \pi_\theta(y \mid x)$$

- **Quy trình trực tiếp của DPO (Phần 3):** Dùng closed-form solution của bài toán RLHF để biểu diễn $r(x, y)$ theo $\pi_\theta(y \mid x)$, từ đó tối ưu trực tiếp π_θ trên cặp mẫu dương/âm (y_w, y_l)!

Tiêu chí Hệ thống	**RLHF + PPO (Phần 2 – 2022)**	**DPO (Phần 3 – 2023)**
Số mô hình trong VRAM	**4 mạng:** $\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi$	**2 mạng:** Chỉ cần π_θ và π_{ref}
Autoregressive Decoding lúc học	Bắt buộc ở mọi bước cập nhật (*Rollout*)	**Không cần** (Tính log-prob song song)

Bài toán có KL regularization và phân phối Gibbs–Boltzmann (B1).

RLHF Objective và closed-form solution (B1)

Bài toán cực trị có KL regularization:

$$\max_{\pi} \mathbb{E}_{y\sim\pi}\left[r(x,y) - \beta \log \frac{\pi(y \mid x)}{\pi_{\text{ref}}(y \mid x)}\right]$$

Nghiệm cực trị Gibbs–Boltzmann (BĐT Gibbs):

$$\pi^*(y \mid x) = \frac{1}{Z(x)}\pi_{\text{ref}}(y \mid x)\exp\left(\frac{1}{\beta}r(x,y)\right)$$

Biểu diễn ngược Reward Function:

$$\boxed{r(x,y) = \beta \log \frac{\pi^*(y \mid x)}{\pi_{\text{ref}}(y \mid x)} + \beta \log Z(x)}$$

($Z(x) = \sum_y \pi_{ref}\exp(\frac{1}{\beta}r)$: Partition Function)

Từ closed-form solution của RLHF đến Loss trực tiếp (B7).

Khử $Z(x)$ và xây dựng DPO (B7)

Thế vào xác suất cặp Bradley–Terry:
Khi lấy hiệu số $r(x, y_w) - r(x, y_l)$, đại lượng $\beta \log Z(x)$ **tự triệt tiêu hoàn toàn**:

$$r(x, y_w) - r(x, y_l) = \beta \log \frac{\pi^*(y_w \mid x)}{\pi_{\text{ref}}(y_w \mid x)} - \beta \log \frac{\pi^*(y_l \mid x)}{\pi_{\text{ref}}(y_l \mid x)}$$

DPO Loss (B7)

Thay π^* bằng π_θ, tối ưu MLE trên tập cặp:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\,\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\hat{r}_\theta(x, y_w) - \hat{r}_\theta(x, y_l)\right)\right]$$

với phần thưởng ngầm định: $\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y|x)}{\pi_{\text{ref}}(y|x)}$.

Gradient của DPO

Tự điều chỉnh biên độ cập nhật giữa mẫu dương y_w và mẫu âm y_l.

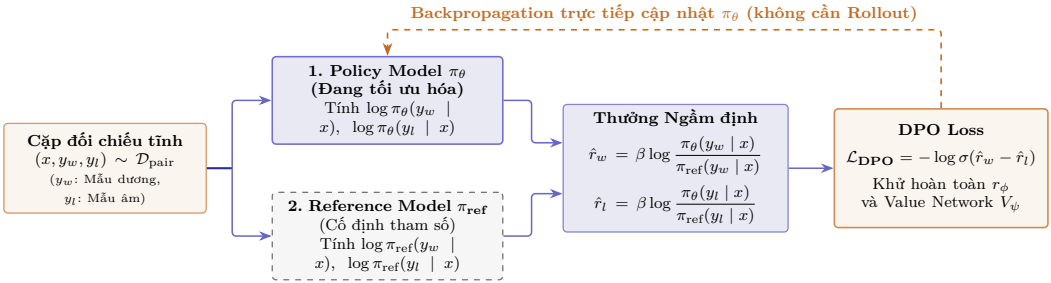
Gradient đầy đủ (Rafailov et al., 2023)

$$\nabla_\theta \mathcal{L}_{\text{DPO}}(\theta) = -\beta\, \mathbb{E}_{(x,y_w,y_l)} \Big[\underbrace{\sigma\big(\hat{r}_\theta(x,y_l) - \hat{r}_\theta(x,y_w)\big)}_{\text{Hệ số lỗi xếp hạng } \in (0,1)} \cdot \Big(\underbrace{\nabla_\theta \log \pi_\theta(y_w \mid x)}_{\text{Kéo Mẫu dương } y_w\ (\uparrow)} - \underbrace{\nabla_\theta \log \pi_\theta(y_l \mid x)}_{\text{Đẩy Mẫu âm } y_l\ (\downarrow)} \Big) \Big]$$

Trọng số thay đổi theo lỗi xếp hạng

- **Khi mô hình xếp hạng sai ($\hat{r}_\theta(x,y_l) > \hat{r}_\theta(x,y_w)$):**
  Hệ số lỗi $\sigma(\hat{r}_l - \hat{r}_w) > 0.5$ (tiệm cận 1.0), tự động **tăng biên độ gradient** để sửa lỗi xếp hạng.
- **Khi mô hình đã phân loại đúng ($\hat{r}_\theta(x,y_w) \gg \hat{r}_\theta(x,y_l)$):**
  Hệ số $\sigma(\hat{r}_l - \hat{r}_w) \to 0$, gradient tự triệt tiêu $\to$ **ngăn ngừa quá khớp** trên các mẫu đã học tốt.
- **Tác động đối ngẫu:**
  Đồng thời tăng hợp lý của mẫu dương y_w và giảm xác suất của mẫu âm y_l.

Chỉ giữ Policy π_θ và Reference Model π_{ref}.



Ưu thế hệ thống: Tính toán log-xác suất song song trên toàn chuỗi (y_w, y_l) trong một forward pass duy nhất.

Length Bias, Likelihood Displacement và yêu cầu dữ liệu cặp.

Ba hạn chế của DPO

1. **Length Bias:**
   Tổng $\log \pi_\theta(y \mid x) = \sum_{t=1}^{|y|} \log \pi_\theta(y_t \mid x, y_{<t})$ tỷ lệ thuận với $|y|$, gây ưu tiên mẫu dài dòng.
2. **Likelihood Displacement:**
   Chỉ tối ưu hiệu số $\hat{r}_w - \hat{r}_l$, có thể làm cả $\log \pi_\theta(y_w)$ lẫn $\log \pi_\theta(y_l)$ cùng giảm.
3. **Đòi hỏi cặp đồng truy vấn** (x, y_w, y_l)**:**
   Không tận dụng được dữ liệu đánh giá nhị phân đơn lẻ.

Các biến thể của DPO (2024)

SimPO, RPO / CPO, IPO và KTO xử lý những giới hạn khác nhau.

Các hướng cải tiến (2024)

- **SimPO (Meng et al., 2024):**
  Chuẩn hóa độ dài $\frac{\beta}{|y|}\log \pi_\theta(y \mid x)$ và thay π_{ref} bằng hằng số biên $\gamma > 0$ (chỉ cần **1 mô hình**).
- **RPO / CPO (2024):**
  Cộng thêm $\alpha \mathcal{L}_{\text{SFT}}(y_w)$ để neo xác suất tuyệt đối của mẫu dương y_w.
- **IPO (Azar et al., 2024):**
  Loss bình phương ngăn quá khớp khi xác suất cặp tiệm cận 1.
- **KTO (Ethayarajh et al., 2024):**
  Học trực tiếp từ mẫu dương hoặc mẫu âm đơn lẻ.

DPO thay đổi hệ thống RLHF như thế nào?

Đối chiếu DPO và các biến thể (2023–2024) với PPO (2022).

Đóng góp so với RLHF + PPO

Tiêu chí đánh giá	RLHF + PPO (Phần 2 – 2022)	DPO & Biến thể (Phần 3 – 2023–2024)
1. Cơ sở giải tích	Xấp xỉ lặp qua gradient Monte Carlo và mạng r_ϕ, V_ψ	**Boltzmann closed-form solution**: Khử hoàn toàn Partition Function $\beta \log Z(x)$
2. Bộ nhớ GPU	**4 mạng:** $\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi$	**2 mạng** $(\pi_\theta, \pi_{\text{ref}})$ với DPO, hoặc **1 mạng** với SimPO
3. Tốc độ tính toán	Chậm do Autoregressive Decoding tuần tự (*Rollout*)	**Tăng tốc vượt bậc**: Truyền thuận song song trên cặp (y_w, y_l)
4. Tính ổn định	Phương sai gradient cao, nhạy cảm siêu tham số	Hội tụ ổn định tương đương SFT (ứng dụng trên Llama 3, Qwen 2, Zephyr)

Vì sao quay lại Online RL vào cuối 2024?

1. **Off-policy Exploration Bottleneck:**
   DPO chỉ tối ưu trên tập cặp tĩnh $\mathcal{D}_{\text{pair}}$ thu thập trước; không thể tự khám phá các quỹ đạo suy luận mới nằm ngoài tập dữ liệu.
2. **Định giá bằng mạng nơ-ron trên toán học và thuật toán:**
   Trong bài toán suy luận đa bước, cả DPO lẫn mạng r_ϕ đều bị đánh lừa bởi các lời giải trình bày đẹp nhưng sai kết quả (*Reward Hacking*).
3. **Điểm nghẽn Value Network V_ψ khi Quay lại Online RL:**
   Nếu dùng lại PPO (Phần 2) cho chuỗi suy luận dài 10,000 token, Critic V_ψ bị suy biến do phần thưởng thưa ở cuối chuỗi.

Tiếp theo: RLVR và GRPO (cuối 2024–2026)

Kết hợp **Deterministic Verifier (RLVR)** chống *Reward Hacking* và giải thuật **GRPO** chuẩn hóa nhóm G quỹ đạo để **xóa bỏ Critic** V_ψ.

PHẦN 4 / 05

RLVR và GRPO

Cuối 2024–2026

Nội dung: Kiểm chứng kết quả, chuẩn hóa nhóm và học suy luận.

RLVR xử lý sai số của Reward Model trong toán học và lập trình (2024–2025).

Giới hạn của Reward Model r_ϕ trong Suy luận

- **Thiên kiến hình thức bề mặt:** Mạng r_ϕ gán điểm cao cho lời giải trình bày LaTeX chặt chẽ dù biến đổi sai ở bước cuối.
- **Reward Hacking trên chuỗi dài:** Khi chạy RL nhiều bước, π_θ sinh lập luận ngụy biện để đánh lừa r_ϕ thay vì giải đúng bài toán.

RL với Verifiable Rewards

- Trong miền hình thức (Toán học, Lập trình, Logic), **tính đúng đắn của nghiệm là khách quan và tất định**.
- Thay thế mạng r_ϕ bằng **Deterministic Verifier**:
  - *Toán học:* Đối sánh đại số biểu thức trong `\boxed{}` với y_{gold}.
  - *Lập trình:* Biên dịch và thực thi bộ kiểm thử (Unit Tests).

Kiểm chứng kết quả thay cho đánh giá văn phong (Lambert et al., 2024; DeepSeek-AI, 2025).

Reward Function nhị phân tất định

$$R_{\text{RLVR}}(x, y) = \begin{cases} 1 & \text{nếu Verify}(\text{ExtractAnswer}(y),\ y_{\text{gold}}) = \text{True} \\ 0 & \text{trong mọi trường hợp còn lại} \end{cases}$$

Đặc tính của RLVR khi tối ưu dài hạn

- **Bất biến với nhiễu bề mặt:** Bất kể độ dài hay văn phong lập luận, sai lệch kết quả cuối cùng hoặc trượt kiểm thử đều nhận $R_{\text{RLVR}} = 0$.
- **Zero OOD Degradation:** Cho phép duy trì vòng lặp RL qua hàng chục nghìn bước cập nhật để khám phá chuỗi suy luận sâu (như OpenAI o1/o3, DeepSeek-R1).

Credit Assignment: ORM và PRM

Thưởng cho kết quả cuối hay cho từng bước suy luận? (Lightman et al., 2023).

Credit Assignment trên chuỗi suy luận $y = (s_1, s_2, \ldots, s_K)$

Outcome Reward Model (ORM)

- **Cơ chế:** Chỉ cấp một điểm thưởng duy nhất tại cuối chuỗi y.
- **Ưu điểm:** Không cần nhãn bước trung gian; tương thích trực tiếp với bộ kiểm chứng RLVR.
- **Hạn chế lý thuyết:** Tín hiệu thưa (*Sparse Reward*) — phạt đồng loạt mọi bước trong quỹ đạo sai.

Process Reward Model (PRM)

- **Cơ chế:** Cấp điểm thưởng r_k ngay sau từng bước biến đổi trung gian s_k.
- **Ưu điểm lý thuyết:** Tín hiệu dày đặc (*Dense Credit Assignment*) — bảo toàn các bước đầu đúng và định vị chính xác bước phát sinh lỗi.

Giới hạn của PRM trong huấn luyện RL

Vì sao DeepSeek-R1 (2025) chuyển về ORM dựa trên luật?

Ba giới hạn của PRM khi huấn luyện dài hạn

1. **Step Boundary Ambiguity:**
   Tư duy tự do (thử nghiệm, tự phản biện, quay lui) không thể phân tách cứng nhắc thành các bước đồng nhất.

2. **Chi phí gán nhãn quá trình đắt đỏ:**
   Deterministic Verifier không chấm được bước nháp dở dang; huấn luyện mạng PRM đòi hỏi gán nhãn thủ công hoặc chạy tìm kiếm cây Monte Carlo (MCTS) tốn kém.

3. **Step-level Reward Hacking:**
   Do PRM vẫn là mạng xấp xỉ thần kinh, Policy π_θ học cách chia lời giải thành hàng trăm bước biến đổi hiển nhiên ("$1 = 1 \implies 2 = 2$") để tích lũy điểm dương giả tạo.

GRPO: thay Critic bằng thống kê nhóm

PPO gặp giới hạn khi chuỗi suy luận dài và phần thưởng thưa.

PPO trên chuỗi suy luận dài

1. **Chi phí bộ nhớ gấp đôi từ Critic V_ψ:**
   Phải lưu trữ và cập nhật mạng V_ψ (70B–671B tham số) song song với π_θ.
2. **Phương sai cao của $V_\psi(s_t)$ dưới phần thưởng thưa:**
   Trong RLVR, điểm thưởng $\{0, 1\}$ chỉ xuất hiện ở token cuối thứ 10,000; việc ước lượng $V_\psi(s_t)$ tại token $t \ll T$ có sai số rất lớn, làm lệch Advantage $\hat{A}_t$.

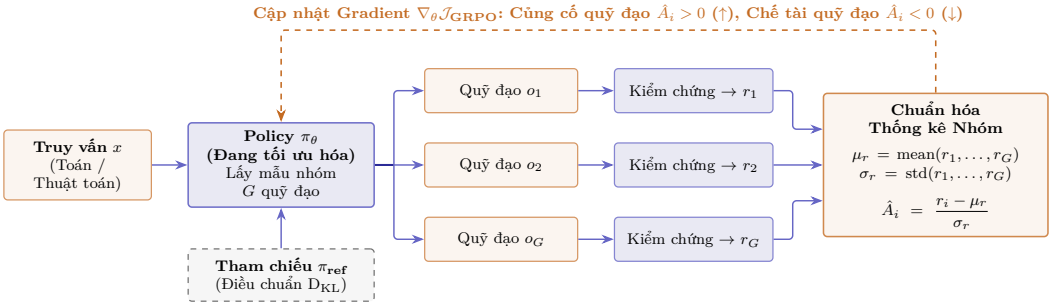
GRPO (Shao et al., 2024 – DeepSeekMath)

Nguyên lý: Khử hoàn toàn Value Network V_ψ.

1. Với mỗi truy vấn x, lấy mẫu song song một nhóm G quỹ đạo $\{o_1, o_2, \ldots, o_G\} \sim \pi_{\theta_{\text{old}}}(\cdot \mid x)$.
2. Chấm điểm cả nhóm bằng bộ kiểm chứng RLVR: $\{r_1, r_2, \ldots, r_G\}$.
3. Dùng trung bình nhóm μ_r làm baseline $b(x)$ và chuẩn hóa Z-score theo σ_r.

RLVR + GRPO: luồng huấn luyện

Lấy mẫu nhóm G quỹ đạo và cập nhật Policy, không cần Value Network.



PPO-Clip kết hợp chuẩn hóa phần thưởng theo nhóm (Shao et al., 2024).

GRPO Objective và Advantage chuẩn hóa $\hat{A}_i$

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x,\,\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\text{old}}}} \left[\frac{1}{G}\sum_{i=1}^{G} \frac{1}{|o_i|}\sum_{t=1}^{|o_i|} \Big(\min\left(\rho_{i,t}\hat{A}_i,\ \text{clip}(\rho_{i,t}, 1-\epsilon, 1+\epsilon)\hat{A}_i\right) - \beta\, \mathrm{D}_{\text{KL}}(\pi_\theta \,\|\, \pi_{\text{ref}}) \Big) \right]$$

Với Advantage chuẩn hóa Z-score cho mọi token $t \in \{1, \ldots, |o_i|\}$:

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, r_2, \ldots, r_G)}{\text{std}(r_1, r_2, \ldots, r_G)}$$

- **Đồng nhất Advantage cấp chuỗi ($\hat{A}_{i,t} \equiv \hat{A}_i$):** Mọi token thuộc quỹ đạo o_i chia sẻ chung trọng số Advantage $\hat{A}_i$.
- **Tự thích nghi theo độ khó của x:** Phép chuẩn hóa Z-score giữ kỳ vọng $\mathbb{E}[\hat{A}_i] = 0$ và phương sai $\text{Var}(\hat{A}_i) = 1$ ổn định trên mọi bài toán.

Ví dụ GRPO: nhóm bốn quỹ đạo

Chuẩn hóa nhóm phân tách Advantage của mẫu giải đúng và mẫu giải sai.

Xét truy vấn toán học x với nhóm $G = 4$ quỹ đạo tự sinh $\{o_1, o_2, o_3, o_4\}$
($\mu_r = 0.275, \sigma_r = 0.42$)

Quỹ đạo	**Kết quả kiểm chứng**	**Điểm r_i**	**Advantage** $\hat{A}_i = \frac{r_i - 0.275}{0.42}$	**Hướng cập nhật gradient**
Quỹ đạo o_1	Đáp số **Đúng** + Đúng thẻ `<think>`	$r_1 = \mathbf{1.0}$	$\hat{A}_1 = \mathbf{+1.72} > \mathbf{0}$	**Tăng mạnh xác suất (↑↑)**
Quỹ đạo o_2	Đáp số **Sai**, đúng thẻ `<think>`	$r_2 = \mathbf{0.1}$	$\hat{A}_2 = \mathbf{-0.41} < \mathbf{0}$	**Giảm nhẹ xác suất (↓)**
Quỹ đạo o_3	Đáp số **Sai** + Sai cấu trúc	$r_3 = \mathbf{0.0}$	$\hat{A}_3 = \mathbf{-0.65} < \mathbf{0}$	**Giảm mạnh xác suất (↓↓)**
Quỹ đạo o_4	Đáp số **Sai** + Sai cấu trúc	$r_4 = \mathbf{0.0}$	$\hat{A}_4 = \mathbf{-0.65} < \mathbf{0}$	**Giảm mạnh xác suất (↓↓)**

Không cần Value Network V_ψ, chuẩn hóa nhóm tự động gán Advantage dương cho quỹ đạo đúng duy nhất (o_1) và đẩy các quỹ đạo sai xuống miền Advantage âm.

Dr. GRPO và DAPO (2025)

Điều chỉnh Length Bias và hiện tượng Entropy Collapse.

Length Bias $\longrightarrow$ Dr. GRPO (Liu et al., 2025)

- **Khiếm khuyết của GRPO gốc:** Chia tổng Advantage cho độ dài chuỗi $\frac{1}{|o_i|}$ trong Công thức 8.
- **Hệ quả:** Với mẫu âm ($\hat{A}_i < 0$), chuỗi sai càng dài ($|o_i|$ lớn) thì mức phạt trung bình trên mỗi token càng nhẹ $\Longrightarrow$ mô hình kéo dài câu trả lời sai.
- **Hiệu chỉnh Dr. GRPO:** Bỏ hệ số chia $\frac{1}{|o_i|}$ và σ_r, giữ estimator gradient không chệch.

Entropy Collapse $\longrightarrow$ DAPO (Yu et al., 2025)

- **Giới hạn của symmetric clipping $[1-\epsilon, 1+\epsilon]$:** Với $\epsilon = 0.2$, token khám phá mới ($\pi_{\text{old}} = 0.01$) bị chặn trên tại 0.012, kìm hãm đa dạng suy luận.
- **Hiệu chỉnh Clip-Higher (DAPO):** Tách cận asymmetric clipping $[\mathbf{1} - \epsilon_{\text{low}},\ \mathbf{1} + \epsilon_{\text{high}}]$ với $\epsilon_{\text{high}} > \epsilon_{\text{low}}$ để duy trì entropy khám phá.

Sự hình thành Chain-of-Thought

Quan sát trên DeepSeek-R1-Zero (DeepSeek-AI, 2025).

Thiết kế phần thưởng

Chạy GRPO trực tiếp trên Base Model (không qua SFT), chỉ dùng **2 quy tắc kiểm chứng**:

1. **Accuracy Reward (r_{acc}):** Kiểm tra tính tương đương đại số của đáp số cuối.
2. **Format Reward (r_{format}):** Kiểm tra cấu trúc thẻ `<think>...</think>` và `<answer>...</answer>`.

Chú ý: Không có bất kỳ Reward Function nào quy định nội dung hay độ dài bên trong thẻ `<think>`.

Sự hình thành tư duy System 2

- Các quỹ đạo tự phân bổ nhiều token trong `<think>` để **phân rã bài toán, kiểm định giả thuyết và tự sửa lỗi** đạt xác suất giải đúng ($r_{\text{acc}} = 1$) vượt trội.
- Qua chọn lọc tự nhiên của $\hat{A}_i > 0$, Policy tự củng cố hành vi siêu nhận thức (*Metacognitive Self-Correction*).
- Chuyển dịch từ **Phản xạ System 1** sang **Suy luận System 2**.

Từ suy luận nội tại đến tác tử tương tác với môi trường (2025–2026).

Test-time Scaling (Snell et al., 2024)

Hiệu năng suy luận tăng theo ngân sách tính toán lúc giải mã trên 2 trục trực giao:

- **Sequential Scaling:**
  Kéo dài chuỗi `<think>` để tự kiểm tra và hiệu chỉnh sai số trên một quỹ đạo.
- **Parallel Scaling:**
  Lấy mẫu N quỹ đạo độc lập, hợp nhất bằng **Self-Consistency (Majority Voting)** hoặc **Best-of-N**.

Agentic RL và Rubric RL (2025–2026)

- **Agentic RL Đa vòng (Multi-turn Tool-Use RL):**
  Nhúng GRPO vào môi trường thực thi: suy nghĩ `<think>` → gọi công cụ (Terminal, Compiler, Search) → nhận phản hồi môi trường → suy luận tiếp.
- **Rubric-based RL & GenRM:**
  Mở rộng RLVR sang tác vụ mở bằng bộ tiêu chí kiểm chứng phân rã (Checklists) và Reward Model có suy luận (*Generative Reward Model*).

RLVR + GRPO cải thiện DPO và PPO ra sao?

Những đóng góp cho suy luận System 2 (cuối 2024–2026).

Đóng góp so với DPO và PPO

Tiêu chí đánh giá	PPO (Phần 2) & DPO (Phần 3)	RLVR + GRPO (Phần 4 – 2024–2026)
1. Tín hiệu định giá	Mạng r_ϕ hoặc cặp tĩnh (bị *Reward Hacking* trên Toán/Code)	**Deterministic Verifier (RLVR)**: Khách quan tuyệt đối, triệt tiêu gian lận hình thức
2. Ước lượng baseline	PPO cần Critic V_ψ lớn, sai số cao trên chuỗi dài	**Chuẩn hóa nhóm G quỹ đạo (GRPO)**: Khử hoàn toàn Critic V_ψ, giảm 50% VRAM
3. Năng lực suy luận	Phản xạ System 1 (học tĩnh trên dữ liệu sẵn có)	**Tư duy System 2 (`<think>`)**: Tự khám phá trực tuyến và mở rộng tính toán lúc chạy

Vì sao mô hình nhỏ cần chuyển giao năng lực qua Distillation?

Ba giới hạn trên mô hình nhỏ (1.5B–14B)

1. **Điều kiện Cần của Giải thuật GRPO ($\sigma_r > 0$):**
   Trong nhóm G quỹ đạo $\{o_1, \ldots, o_G\}$, bắt buộc phải xuất hiện ít nhất một vài mẫu dương giải đúng để tạo độ lệch chuẩn $\sigma_r > 0$.
2. **Hiện tượng Cạn kiệt Phần thưởng & Triệt tiêu Gradient ($\nabla_\theta \mathcal{J} = \mathbf{0}$):**
   Trước bài toán khó, mô hình nhỏ (1.5B–14B) giải sai cả $G = 64$ lần thử ($r_1 = \cdots = r_G = 0 \implies \hat{A}_i = 0 \implies \nabla_\theta \mathcal{J} = \mathbf{0}$). Quá trình học hoàn toàn bất động!
3. **Chi phí Tính toán của Khám phá RL từ Đầu:**
   Chỉ khả thi trên mô hình Frontier dung lượng lớn (như 671B).

Tiếp theo: Knowledge Distillation

Sử dụng mô hình Frontier đã qua RL làm **Teacher Model (π_T)** để truyền thẳng phân phối dự đoán $P_T^{(\tau)}$ và quỹ đạo suy luận `<think>` sang **Student Model (π_S)**.

PHẦN 5 / 05

Knowledge Distillation

Teacher Model, Student Model và tổng kết

Nội dung: Ba phương thức Distillation, LoRA, Model Merging và đánh giá.

Năm giai đoạn của Post-training: từ SFT đến Knowledge Distillation

Chuyển năng lực từ mô hình Frontier sang mô hình nhỏ, vượt điểm nghẽn của RL.

Teacher–Student Learning (Hinton et al., 2015; Kim & Rush, 2016)

Chuyển phân phối xác suất và quỹ đạo suy luận từ **Frontier Teacher Model** (π_T) đã qua huấn luyện RL quy mô lớn sang **Student Model** (π_S) có dung lượng tham số nhỏ.

Ba phương thức chuyển giao

1. **Logit Distillation (White-box KD):**
   Đối khớp phân phối xác suất mềm $P_T^{(\tau)}(\cdot \mid s_t)$ trên toàn bộ từ điển $\mathcal{V}$ tại từng token.
2. **Sequence-Level Distillation (Black-box KD):**
   Tối đa hóa hợp lý logarit trên phản hồi hoàn chỉnh $y_T \sim \pi_T(\cdot \mid x)$.
3. **Rationale Distillation (Reasoning KD):**
   Chuyển giao đồng thời chuỗi lập luận trung gian `<think>` z_T đã kiểm chứng và kết luận y_T.

Distillation và tự chạy RL: đối chứng thực nghiệm

Kết quả trên Qwen-32B-Base (DeepSeek-AI, 2025).

Tự chạy GRPO và Distillation từ Teacher 671B

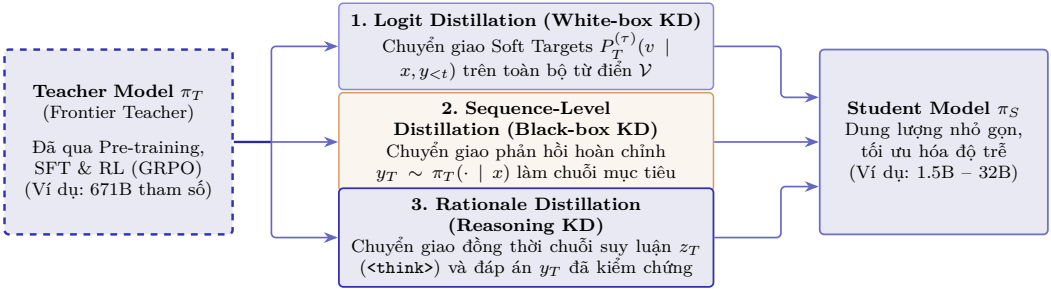
Phương thức huấn luyện trên Qwen-32B	**AIME 2024**	**MATH-500**	**Giải thích cơ chế**
1. Tự chạy RL từ đầu (Zero-RL / GRPO $>10{,}000$ **bước)**	47.0%	83.9%	Bị giới hạn bởi dung lượng khám phá tiên nghiệm của mạng 32B
2. Rationale Distillation từ Teacher DeepSeek-R1 671B	**72.6%**	**94.3%**	**Vượt trội** +25.6% nhờ kế thừa trực tiếp quỹ đạo suy luận của Teacher 671B

Vai trò của RL và Distillation

Dùng **Online RL (RLVR + GRPO)** trên mô hình Frontier để **khám phá tri thức suy luận mới**; dùng **Rationale Distillation** để nén năng lực đó xuống mô hình nhỏ.

Ba phương thức Knowledge Distillation

Luồng tín hiệu huấn luyện trong Distillation hộp trắng và hộp đen.



Điều kiện kỹ thuật: Phương thức 1 đòi hỏi cùng bộ từ vựng $\mathcal{V}$ và truy cập vector logit (*White-box*); Phương thức 2 & 3 chỉ dùng văn bản đầu ra nên áp dụng được cho mọi cặp mô hình (*Black-box*).

Temperature-scaled Softmax và tương đồng ngữ nghĩa (Hinton et al., 2015).

Temperature-scaled Softmax τ và mục tiêu Logit KD

$$P^{(\tau)}(v_k \mid s_t) = \frac{\exp(z_k/\tau)}{\sum_{j=1}^{|\mathcal{V}|}\exp(z_j/\tau)}, \qquad \mathcal{L}_{\text{Logit-KD}}(\theta_S) = \tau^2\, \mathrm{D}_{\mathrm{KL}}\left(P_T^{(\tau)}(\cdot \mid s_t) \,\middle\|\, P_S^{(\tau)}(\cdot \mid s_t)\right)$$

Dark Knowledge

- Hard Labels (One-hot) chỉ gán xác suất 1 cho 1 từ và 0 cho $|\mathcal{V}| - 1$ từ còn lại.
- Soft Targets $P_T^{(\tau)}$ (ví dụ: *"mèo"*: 0.70, *"chó"*: 0.25, *"tủ lạnh"*: 10^{-8}) truyền tải **cấu trúc hình học tương đồng giữa các khái niệm**.

Vai trò của nhiệt độ $\tau > 1$ và Hệ số τ^2

- **Chia cho $\tau > 1$:** Làm phẳng phân phối Softmax, nâng xác suất vùng đuôi để Student tiếp nhận rõ cấu trúc tương quan.
- **Nhân với τ^2:** Bù lại sự suy giảm biên độ gradient $\nabla_{z_S} \mathrm{D}_{\mathrm{KL}} \propto 1/\tau^2$.

Sequence KD học kết quả; Rationale KD học thêm chuỗi `<think>`.

Rationale Distillation Objective (Hsieh et al., 2023)

$$\mathcal{L}_{\text{Rationale-KD}}(\theta_S) = -\,\mathbb{E}_{(x,z_T,y_T)\sim\mathcal{D}_{\text{verified}}}\Big[\log \pi_S(z_T \mid x) + \log \pi_S(y_T \mid x, z_T)\Big]$$

Sequence KD ($x \mapsto y_T$)

- Đáp án cuối y_T là kết quả của nhiều bước biến đổi ẩn bên trong Teacher Model lớn.
- Lược bỏ chuỗi suy luận trung gian z_T khiến Student Model (ít tầng ẩn hơn) rơi vào trạng thái **Surface Pattern Matching**.

Rationale KD ($x \mapsto z_T \mapsto y_T$)

- Lọc mẫu theo ngưỡng kiểm chứng (*Rejection Sampling*) để giữ các cặp (z_T, y_T) đúng của Teacher.
- Sinh chuỗi `<think>` z_T trước giúp phân rã bài toán khó thành chuỗi các bước dự đoán cục bộ đơn giản trên ngữ cảnh.

Hai cách khớp phân phối giữa Teacher và Student (Gu et al., 2024).

Hai chiều KL giữa Teacher (P_T) và Student (P_S)

1. Forward KL: $\mathrm{D_{KL}}(P_T \parallel P_S) = \sum_y P_T(y) \log \frac{P_T(y)}{P_S(y)}$

2. Reverse KL: $\mathrm{D_{KL}}(P_S \parallel P_T) = \sum_y P_S(y) \log \frac{P_S(y)}{P_T(y)}$

Forward KL: Mean-seeking

- Khi $P_T(y) > 0$, bắt buộc $P_S(y) > 0$ (nếu $P_S \to 0 \implies \log \frac{P_T}{P_S} \to +\infty$).
- Student Model nhỏ cố trải rộng phân phối bao phủ mọi đỉnh của Teacher $\implies$ trọng tâm rơi vào vùng mật độ thấp ở giữa (nơi $P_T(y) \approx 0$).

Reverse KL: Mode-seeking

- Khi $P_T(y) = 0$, bắt buộc $P_S(y) = 0$. Nhưng nếu Student bỏ qua một số đỉnh phụ của Teacher ($P_S(y) = 0$), tích số $0 \log 0 = 0$ không gây phạt.
- Cho phép Student **tập trung** 100% **dung lượng vào một cực đại tốt nhất của Teacher**.

Hai pha huấn luyện cho mô hình nhỏ.

Khắc phục triệt tiêu gradient và Exposure Bias

1. **Pha 1 – Distillation từ Frontier Teacher Model (Logit KD / Rationale KD):** Khởi tạo khả năng suy luận cho mô hình nhỏ, nâng xác suất giải đúng tiên nghiệm từ 0% lên 50%–70%. Tuy nhiên, do học tĩnh trên chuỗi của Teacher, Student Model vẫn chịu *Exposure Bias* và thiếu tín hiệu từ mẫu âm của chính nó.
2. **Pha 2 – Chạy Bồi GRPO (RLVR) và DPO Trực tiếp trên Student Model:** Nhờ Pha 1, nhóm G quỹ đạo lấy mẫu trên mô hình nhỏ đã có cả mẫu dương lẫn mẫu âm ($\sigma_r > 0 \implies \hat{A}_i \neq 0$). GRPO + DPO tiếp tục sửa lỗi lập luận của mô hình nhỏ và vượt giới hạn Distillation tĩnh (ứng dụng trên *Qwen3, Gemma 2/3, DeepScaleR*).

Thích nghi trên không gian hạng thấp và kết hợp Task Vector.

Low Intrinsic Dimensionality và LoRA (Hu et al., 2022)

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r} BA, \quad r \ll \min(d, k)$$

- **Low Intrinsic Dimensionality (Aghajanyan et al.):** Độ lệch ΔW trong Post-Training nằm trên đa tạp con hạng r rất nhỏ ($r \in \{16, 32\}$).
- **Giảm Catastrophic Forgetting (Biderman et al., 2024):** Đóng băng W_0 và chỉ cập nhật $< 1\%$ tham số giúp bảo toàn tri thức gốc của Base Model.

Task Vector và Model Merging

$$\tau_i = \theta^{(i)}_{\text{finetuned}} - \theta_{\text{base}} \implies \theta_{\text{merged}} = \theta_{\text{base}} + \sum_{i=1}^{M} \lambda_i \tau_i$$

- **Linear Mode Connectivity:** Các mô hình tinh chỉnh từ cùng θ_{base} nằm chung trong một vùng trũng Loss (Loss Basin).
- **TIES-Merging & DARE:** Cắt tỉa 90% biến thiên nhỏ và đồng bộ dấu để hợp nhất kỹ năng *Toán* (τ_{math}) và *Hội thoại* (τ_{chat}).

Đánh đổi hiệu năng và hiệu chỉnh thiên kiến (Zheng et al., 2023).

Alignment Tax và Elo

- **Alignment Tax:**
  RLHF / DPO thu hẹp entropy phân phối, làm giảm nhẹ độ đa dạng hoặc hiệu chỉnh xác suất (Calibration).
- **Định lượng Elo (Chatbot Arena):**
  Đánh giá đối kháng mù từng cặp theo mô hình Bradley-Terry:

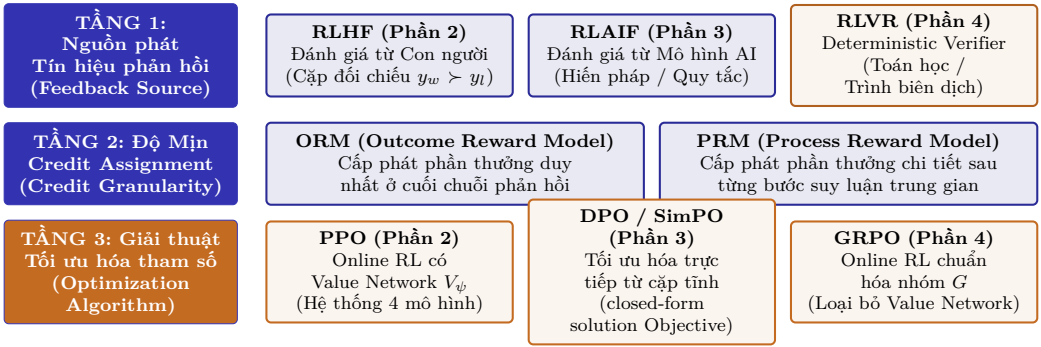
$$P(A \succ B) = \frac{1}{1 + 10^{(R_B - R_A)/400}}$$

Ba thiên kiến của LLM-as-a-Judge

Thiên kiến	**Cách hiệu chỉnh thống kê**
1. Vị trí (*Position*)	Đánh giá 2 chiều hoán vị (A, B) và (B, A)
2. Độ dài (*Verbosity*)	Hồi quy tách phương sai độ dài (*Length-Controlled Win Rate*)
3. Tự tương đồng	Hội đồng đa mô hình hoặc Deterministic Verifier

Ba tầng khái niệm trong Post-training

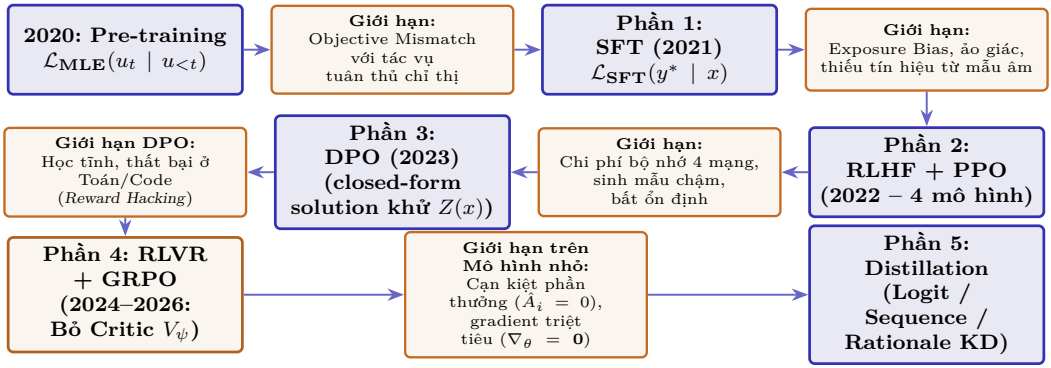
Nguồn phản hồi, độ mịn Credit Assignment và thuật toán tối ưu hóa.



Tổ hợp kiến trúc điển hình theo lịch sử: *InstructGPT (2022)* = **RLHF + ORM + PPO**. | *DeepSeek-R1 (2025)* = **RLVR + ORM + GRPO**.

Chuỗi tiến hóa phương pháp (2020–2026)

Giới hạn của phương pháp trước là động cơ của phương pháp tiếp theo.



Quy trình tích hợp hiện đại: SFT khởi tạo ⟶ RLVR + GRPO khám phá suy luận trên Frontier ⟶ DPO căn chỉnh đa mục tiêu ⟶ Distillation nén xuống mô hình nhỏ.

Đối chiếu các phương pháp: SFT, RLHF và DPO

Tín hiệu học, cấu hình hệ thống, đóng góp và giới hạn (1/2).

Giai đoạn / Phần	**Tín hiệu học**	**Số mô hình**	**Đóng góp so với giai đoạn trước**	**Giới hạn còn lại**
Phần 1: SFT (2020–2021)	Mẫu dương chuẩn (x, y^*)	**1 mạng:** π_θ	Giải quyết *Objective Mismatch*, dạy khuôn mẫu hội thoại nhanh	*Exposure Bias*, kích thích ảo giác, thiếu tín hiệu từ mẫu âm
Phần 2: RLHF+PPO (2022 – ChatGPT)	Điểm thưởng $r_\phi(x, \hat{y})$ trên mẫu tự sinh	**4 mạng:** $\pi_\theta, \pi_{\text{ref}}, r_\phi, V_\psi$	*On-policy learning*, gradient 2 chiều chế tài mẫu âm	Tốn bộ nhớ gấp 4 lần, sinh mẫu chậm, gradient RL bất ổn định
Phần 3: DPO (2023–2024)	Cặp mẫu dương/âm $(x, y_w \succ y_l)$	**2 mạng:** $\pi_\theta, \pi_{\text{ref}}$	closed-form solution khử $Z(x)$, bỏ r_ϕ & V_ψ, ổn định như SFT	*Off-policy learning*, thất bại ở Toán/Code do *Reward Hacking*

Tín hiệu học, cấu hình hệ thống, đóng góp và giới hạn (2/2).

Giai đoạn / Phần	**Tín hiệu học**	**Số mô hình**	**Đóng góp so với giai đoạn trước**	**Giới hạn còn lại**
Phần 4: RLVR+GRPO (Cuối 2024–2026)	Bộ kiểm chứng trên nhóm $\{o_1..o_G\}$	**2 mạng:** $\pi_\theta, \pi_{\text{ref}}$ (+ Verifier)	Bỏ Critic V_ψ, miễn nhiễm *Reward Hacking*, nảy sinh `<think>`	Mô hình nhỏ bị cạn kiệt phần thưởng ($\hat{A}_i = 0 \implies \nabla_\theta = \mathbf{0}$)
Phần 5: Distillation	Phân phối $P_T^{(\tau)}$ hoặc chuỗi (z_T, y_T)	**2 mạng:** Teacher $\pi_T \to$ Student π_S	Truyền thẳng suy luận từ Teacher Frontier xuống mô hình nhỏ	Kết hợp thêm GRPO/DPO nhẹ sau Distillation để khử *Exposure Bias*

Năm nguyên lý và phần thảo luận

Tổng kết chuyên đề Post-training (2020–2026).

Năm nguyên lý chính

1. **Phần 1 (2020–2021 – SFT):** Định hình phân phối tuân thủ chỉ thị $\pi_\theta(y^* \mid x)$, nhưng chịu giới hạn bởi *Exposure Bias* và sự vắng mặt của tín hiệu phạt từ mẫu âm.
2. **Phần 2 (2022 – RLHF & PPO):** Kết hợp Reward Function Bradley-Terry $r_\phi(y_w \succ y_l)$, điều chuẩn vùng tin cậy $\beta\, \mathrm{D}_{\mathrm{KL}}$ và giải thuật PPO giúp căn chỉnh trực tuyến, nhưng chịu gánh nặng bộ nhớ 4 mô hình.
3. **Phần 3 (2023–2024 – DPO):** closed-form solution phân phối Gibbs–Boltzmann kết hợp tính bất biến tịnh tiến Bradley-Terry giúp khử Partition Function $\beta \log Z(x)$, tối ưu hóa trực tiếp trên cặp mẫu dương/âm (y_w, y_l).
4. **Phần 4 (Cuối 2024–2026 – RLVR & GRPO):** Deterministic Verifier kết hợp chuẩn hóa nhóm G quỹ đạo giúp xóa bỏ Value Network V_ψ và kích hoạt Chain-of-Thought System 2 (`<think>`).
5. **Phần 5 (Knowledge Distillation & Không gian tham số):** Rationale Distillation kết hợp *Reverse KL* giúp mô hình nhỏ vượt qua hiện tượng triệt tiêu gradient của RL.

Cảm ơn Quý Thầy Cô và các bạn!

Thảo luận và hỏi đáp (Q&A)